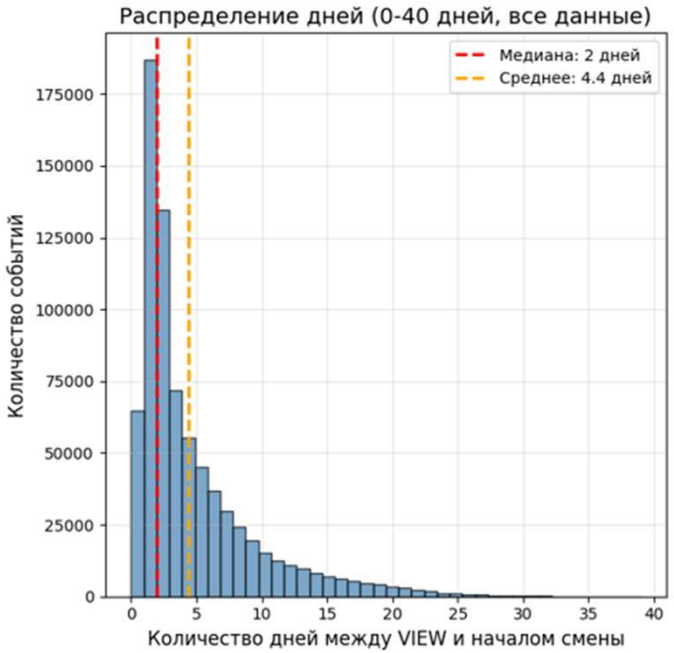
Выбор горизонта прогноза (прогноз за 2 дня до старта смены)

Бизнес-вопрос: насколько заранее нужно предсказывать target, чтобы успеть принять меры?

Для принятия решения проанализировали распределение показателя «количество дней между просмотром и стартом смены»:



Медиана = 2 дня

Критерий	В день старта смены	За 2 дня до смены	За 7+ дней до смены
Свободные места на момент прогноза	0-10%	30-50%	70-90%
Количество исторических признаков	Хорошее	Хорошее	Среднее (теряется недавняя активность)
Бизнес-ценность прогноза	Низкая (поздно реагировать)	Высокая (есть время)	Средняя (слишком рано, нестабильно)

Итоговый вывод: точка за 2 дня до старта оптимальна

К этому моменту уже совершено 70% заявок, но еще есть свободные места, а исторических данных достаточно для качественных признаков

Feature Engineering – группы признаков

Цель: преобразование сырых данных в признаки, предсказывающие вероятность выхода на смену за 2 дня до ее старта

Группа признаков	Пример признака	Описание	Как считался
Признаки смены	reward_per_hour	Оплата в час	reward/hours
	shift_hour	Час начала смены	0-23 из start_at
	is_weekday	Флаг «будний день или нет»	1 – если пн-пт и не праздник, иначе 0
Признаки пользователя	user_success_rate	Доля успешных записей в окне	Отношение выходов к просмотрам (0, если нет view)
	user_high_paid_ratio	Доля высокооплачиваемых смен	-1, если нет выходов. Иначе доля смен с оплатой выше медианной
	user_day_ratio	Доля выходов на дневные смены	-1, если нет выходов. Иначе доля дневных смен
Признаки работодателя	employer_popularity	Популярность среди users	Число уникальных пользователей, работавших у заказчика (за имеющуюся историю, 2-3 мес.)
	employer_avg_reward	Средний размер оплаты смен	Среднее арифметическое reward по всем сменам за имеющуюся историю (2-3 мес.)
Сочетание признаков (взаимодействие)	user_task_type_experience	Опыт с данным типом задачи	1, если пользователь успешно работал с данным типом задачи, иначе 0
	has_apply_before* !	Записывался ли ранее на эту смену	1, если уже записался на эту смену
	mk_match_2	состояние медкнижки	0 – МК нужна, но у пользователя ее нет, 1 – МК нужна и есть, 2 – МК не нужна

Всего создано признаков: 50

! Обнаружили противоречие: за 2 дня до смены уже есть записавшиеся пользователи. По ним будет очень высокая вероятность выхода. Однако показ инфо о смене таким пользователям не имеет бизнес-смысла. Предлагаем исключить их из топ- n наиболее вероятных пользователей

Отбор признаков. Этап №1: ручной

Непрерывные признаки:

Топ-9 признаков по коэффициенту корреляции с таргетом

Признак	r
Доля успешных записей в окне	0,28
Успешных действий за 7 дней	0,20
Успешных действий за 14 дней	0,15
Опыт пользователя в данной локации	0,13
Просмотров смены (всеми пользователями)	-0,08
Кол-во просмотренных смен пользователем	-0,08
Сколько раз пользователь просматривал эту смену	-0,07

Категориальные (в т.ч. бинарные) признаки:

Топ-10 по Cramer's V

Признак	Cramer's V
Кол-во записей у пользователя на смены в тот же день	0,64
Записывался ли ранее на эту смену	0,64
Смена заполнена и пользователь на нее записан	0,58
Опыт пользователя с данным работодателем	0,16
Опыт пользователя с данным типом задач	0,15
Совпадение уровня оплаты смены и предпочтения пользователя	0,12
Совпадение длительности смены и предпочтения пользователя	0,12
Совпадение по времени суток смены и предпочтения user	0,09

! Анализ мультиколлинеарности

Топ высококоррелированных пар (r>0,8)

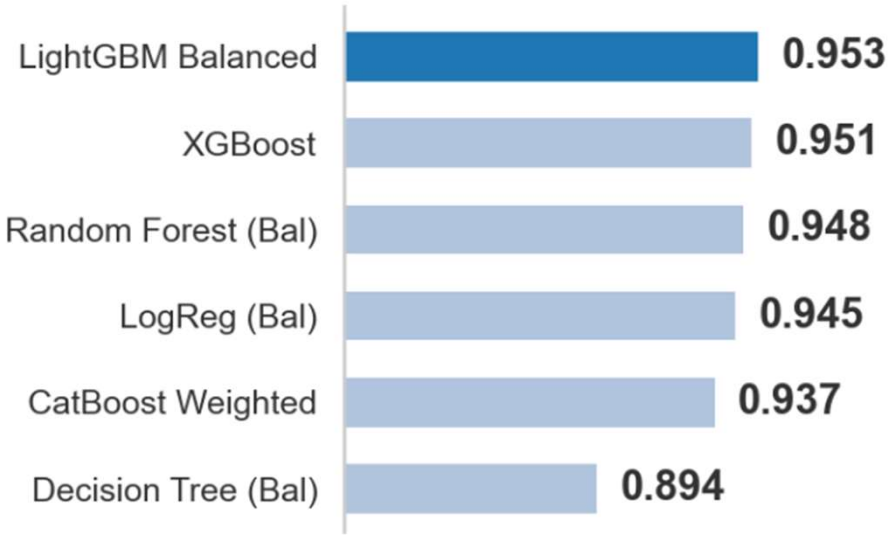
Связанные признаки	r	Рекомендация
Успешных действий ↔ Доля успехов	0,93	Оставить 1 (доля стабильнее)
Уже записался ↔ Заполнено и записался	0.91	Удалить второй (избыточен)
Доля высокооплач. ↔ Средняя оплата	0,88	Оставить среднюю оплату (более информативна)
Оплата за час ↔ Выше медианы окна	0,86	Удалить бинарный признак
Просмотры ↔ Активные дни	0,81	Оставить оба (разный смысл)
Свободные места ↔ Смена заполнена	-0,85	Оставить свободные места (более информативно)

! *Выявлены коррелирующие пары признаков. Для алгоритмов на деревьях удалили только явные дубликаты признаков, остальные оставили - модель сама отобрала нужные*

Сравнение моделей

Цель: выбрать наиболее устойчивую модель для production, использовать модель для отбора признаков

Основной критерий выбора — устойчивый ROC-AUC при работе с дисбалансом классов.



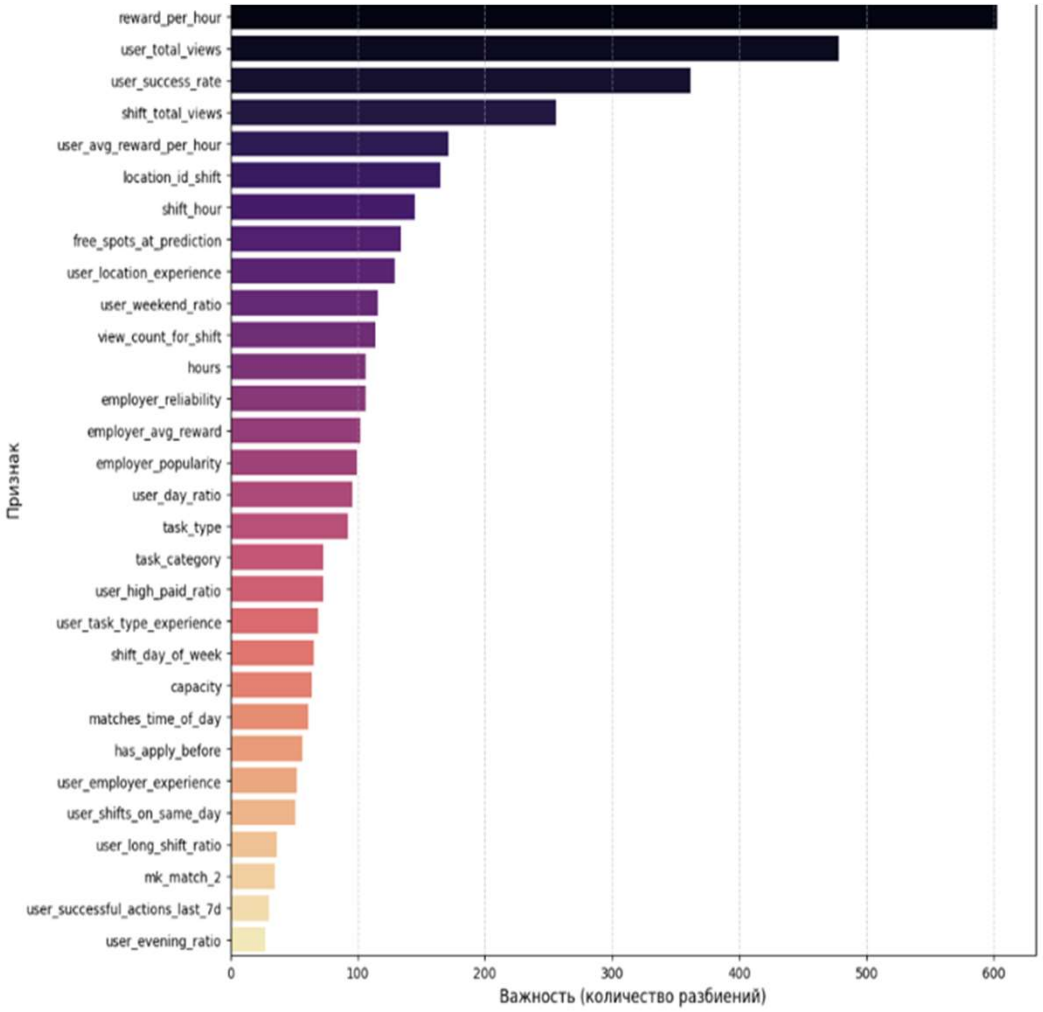
Модель	ROC-AUC	Precision	Recall
CatBoost Weighted	0.937	0.199	0.745
Decision Tree (Bal)	0.894	0.122	0.806
LightGBM Balanced	0.953	0.153	0.833
LogReg (Bal)	0.945	0.106	0.873
Random Forest (Bal)	0.947	0.176	0.764
XGBoost	0.951	0.843	0.433

Итоговый вывод: для production использовать модель LightGBM Balanced

Данная модель наиболее сбалансирована и подходит для реальных задач.

Отбор признаков. Этап №2: на основе feature importance и PSI

Результат: Сократили кол-во признаков с 50 до 26 (отсеяли избыточные и шумовые признаки)



Расшифровка названий топ-10 признаков

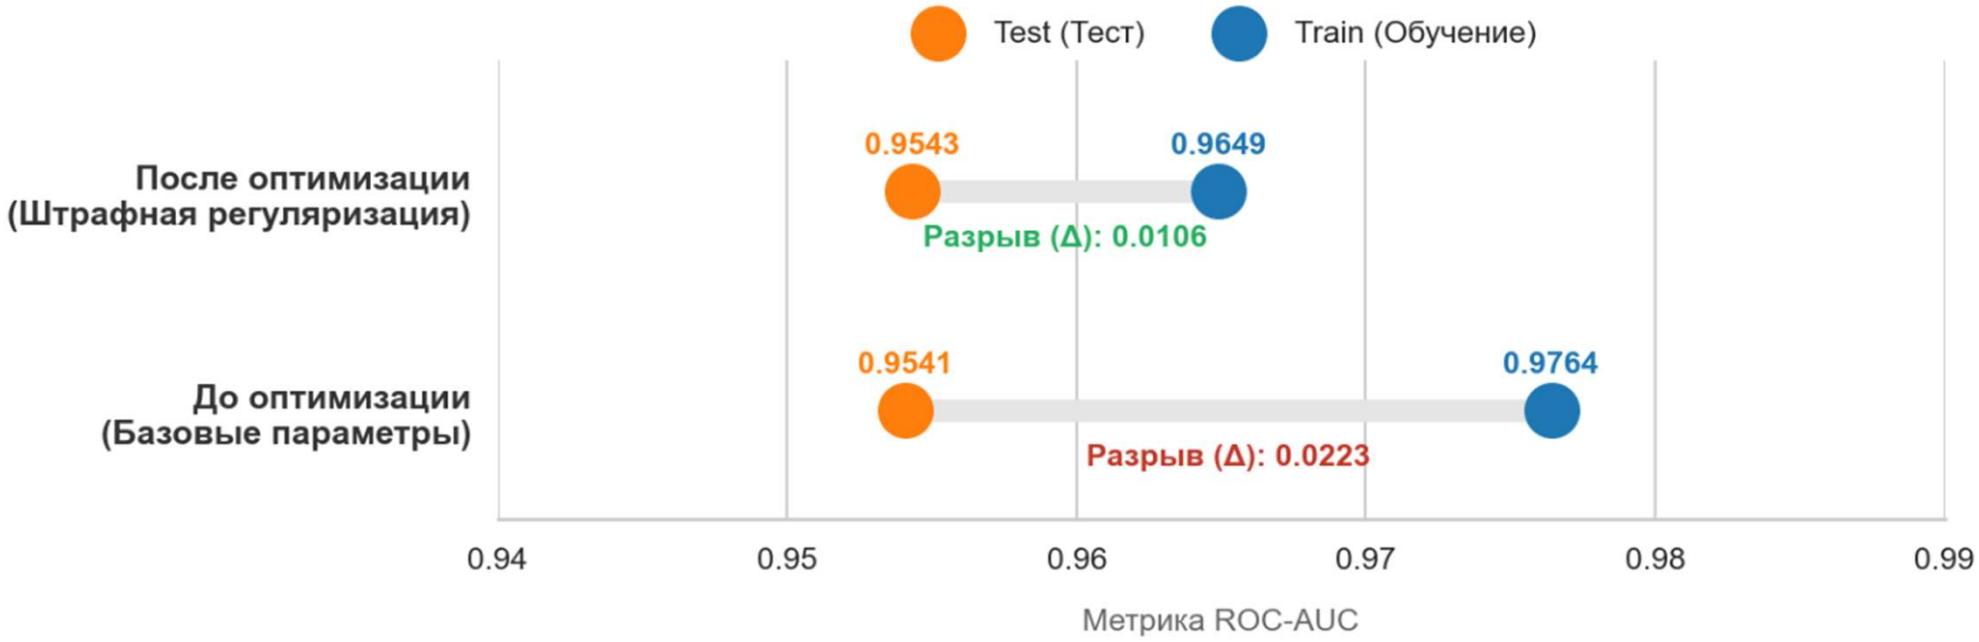
Место	Признак	Содержание
1	reward_per_hour	Оплата в час
2	user_total_views	Кол-во просмотренных смен пользователем
3	user_success_rate	Доля успешных записей
4	shift_total_views	Кол-во просмотров смены пользователями
5	user_avg_reward_per_hour	Средний доход пользователя в час
6	location_id_shift	Локация смены
7	shift_hour	Время начала смены
8	free_spots_at_prediction	Осталось мест
9	user_location_experience	Работал ли user в данной локации
10	user_weekend_ratio	Как часто работает в будни

Сокращение переобучения модели без потери качества

Цель: сократить разрыв между Train и Test без потери качества

- Проведен направленный подбор гиперпараметров (Optuna) с фокусом на жесткую регуляризацию.
- Ограничена максимальная глубина деревьев (max_depth: 3–10) и снизили долю используемых признаков (feature_fraction), чтобы модель не зазубривала тренировочный датасет.

- **Итог**: Модель стала стабильнее на 52%, сохранив точность на тесте (ROC-AUC ~0.954)



Промежуточный итог: Модель готова к использованию в реальных условиях

0.925 / 0.954

ROC-AUC на Test с has_apply_before == 0 / ROC-AUC на Test с has_apply_before == 1

40.0% / 87.0%

Precision на Test с has_apply_before == 0 / Precision на Test с has_apply_before == 1

Бизнес-контекст

При базовой конверсии выборки всего **1.14%**, точность модели в 40% означает, что эффективность коммуникации возрастает в **35 раз** относительно случайного выбора.

Следующие шаги:

Сериализация — сохранение обученной модели LightGBM для деплоя.

Настройка порогов — калибровка Recall под разные бизнес-стратегии.

Запуск приложения — интеграция в репозиторий.

Итоги валидации модели

Масштаб теста

106.1 тыс. / 96.7 тыс.
строк (Train / Test)

115 групп / 676 смен / 22 дня
Массив данных

Качество модели

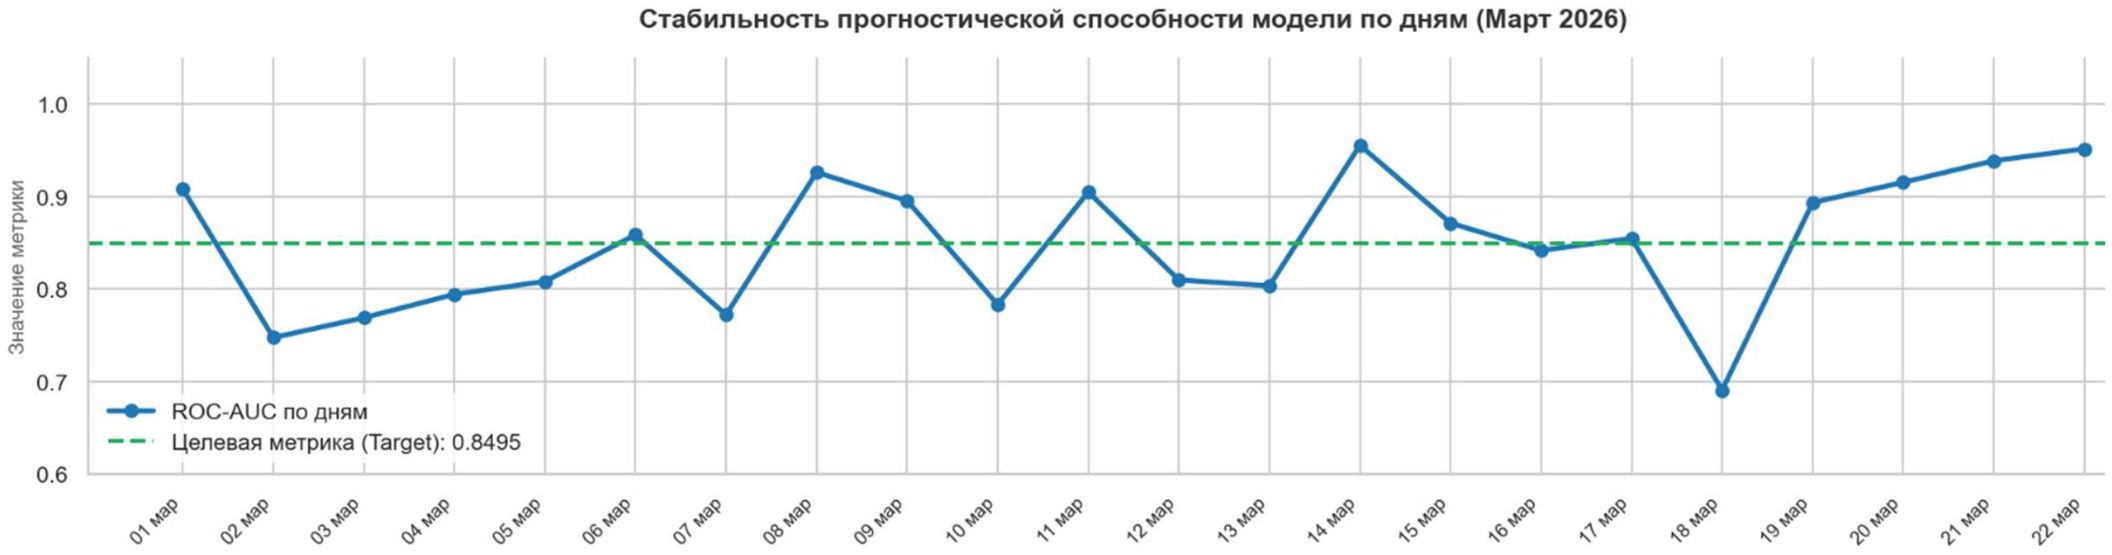
0.929
(ROC-AUC Test)

0.015 (Разрыв Train-Test)
Высокая стабильность в продакшене

Бизнес-эффект

2,053 (True Positive)
точных попаданий

91,840 (True Negative)
сэкономлено на спаме



Нагрузочное тестирование и надежность

Проверка быстродействия сервиса в условиях ограниченных ресурсов

< 19 мс

95% запросов обрабатываются быстрее целевого порога при 200 RPM

100%

Доля успешных ответов
(0% ошибок / failed_calls)

Условия проведения тестирования:

- **Ограничение ресурсов:** Лимиты контейнеров заданы жестко через конфигурацию docker-compose.
- **Конкурентность:** Тестирование параллельной обработки (--predict-max-concurrency 4).
- **Стабильность:** Кодовая база полностью покрыта автоматическими проверками (make test и make precommit).

Метрики производительности (Технический лог):

- **p50 (Медиана):** 15.07 мс
- **p80:** 17.49 мс
- **p95:** 18.69 мс
- **Фактический RPM:** ~200 (199.70)
- **Успешные вызовы:** 100 запросов (`ok_calls`)

```
# Predict load-test report

- p50_ms: 15.071
- p80_ms: 17.492
- p95_ms: 18.692
- rpm: 199.706
- ok_calls: 100
- failed_calls: 0
```

Команда № 11: Роли и вклад в проект

Распределение задач при работе над кейсом



Анализ данных

Журавлев Николай

• Первичный разведочный анализ данных (EDA).
• Исследование структуры исходных датасетов.

Feature Engineering

Селиванова Раиса

• Углубленный EDA и генерация признаков.
• Анализ мультиколлинеарности и связи с таргетом.
• Подготовка датасетов для моделей.

Моделирование

Миронюк Даниил

• Обучение, валидация и сравнение моделей.
• Подбор гиперпараметров и оценка качества.
• Feature Importance и финальный отбор признаков.

Оптимизация и деплой

Губанов Антон (*Тимлид*)

• Координация, архитектура решения и перенос логики в production-приложение.

Юрин Юрий

• Оптимизация кода и ускорение расчета окон при формировании фичей.

Троян Денис

• Помощь в оптимизации кодовой базы и оформление презентации.